连锁餐饮智能体平台 · 总体方案 V1.1 → V2.1

V2.1 重构升级（2026-10-25，经审查报告§6 决策确认后执行） - R1 Agent Harness 四件套（budget/context/loop/eval）落地，评测回路 100 条三 100% - R2 Pulsar 事件驱动：领料→**0.3 秒**实时预警（T+1 升级秒级），orphan 账外领用 HIGH 覆盖 - R3 语义缓存真落地：Milvus+稳定哈希嵌入（ADR-0013），命中 <1s - R4 World Model 业务数字孪生：蒙特卡洛采购推演+置信区间预测 - R5 A2A 最小可用：AgentCard+message/send 跨 Agent 委派 - R7 OTel GenAI 语义约定 span（Console→Loki，ADR-0012） - R8 运营决策页×3+暗色模式；R10 Hermes 实验（66.7% vs 16.7%，ADR-0015） - 压测升级 K6+Locust 七梯度（含 10 万并发连接风暴），详见 05/06 报告 - 文档族：04 审查/05 功能/06 性能/07 ADR 集

项目代号：**智慧餐链 SmartF&B Agent Platform** 编制日期：2026-10-24（V1.0）→ 2026-10-24（V1.1 决策锁定） | 编制依据：《我最惨的 AI 项目复盘》教训库 + 集群实勘 + 2026 前沿技术调研 编制框架：TOGAF 10 ADM（业务/数据/应用/技术四架构）+ GB/T 8567 文档规范 + 等保 2.0 **状态：D1/D2/D5/D6 已确认，进入 Phase 0 执行**

V1.1 变更记录（2026-10-24，甲方决策锁定）

决策	结论	对方案的修订
D1 百万用户口径	✅采纳：100 万注册 / 10 万 DAU / 峰值 2 万在线 / API 5-10K QPS / LLM 50-200 QPS	§1.4 生效，写入合同附件
D2 技术栈	✅采纳并修正：业务侧 Java21+SpringBoot3，**Web 容器排除 Tomcat，改用 Undertow + JDK21 虚拟线程**；智能体侧 Python **Litestar + Granian**（全异步高吞吐，明确弃用	§6/§7 相应更新（ADR-0002）

决策	结论	对方案的修订
	FastAPI 等上一代框架）；前端 Vue3	
D5 Phase 0 先行	✅同意，3 周数据评估+POC	§12.1 启动
D6 起步数据	✅模拟门店数据：**不少于 1 亿条**（销售明细 6000 万+订单头 1500 万+出入库流水 3000 万+废弃 500 万+采购 1 千万+会员 100 万），全部入 TiDB；**Redis 集群须有对应数量级缓存数据且支持 warmup**（菜单/BOM/单位字典/近 30 日库存快照/10 万热点会员档案/1 万语义缓存种子，约 12 万+键，一键 warmup Job 可重放）	§5 新增模拟数据设计（ADR-0003）
D3 GraphQL 网关	默认：MVP 用 Spring for GraphQL 组合 BFF（svc-portal），Apollo Router 列入 Phase 2 再评估	§6.3 修订
D4 核心切口	按建议执行：高价值食材用量差异监控起步	§4.2 生效
D7 C 端载体	默认 H5 先行（小程序资质另办）	记录在案
D8 教学实训包	后置到 Phase 3 后可选	记录在案

0. 文档审批

角色	姓名	结论	日期
甲方（业务决策人）	——	□同意 □修改后同意 □不同意	
甲方（技术负责人）	——	□同意 □修改后同意 □不同意	
乙方（总架构师）	——	已编制	2026-10-24

1. 项目背景、目标与”反模式对策矩阵”

1.1 背景

源项目复盘（PDF）记录了一个 120 万合同餐饮 AI 项目从签约到退款的全过程。其失败根因不是技术，而是工程治理：

1. **签约前未做数据资产评估**，三套异构系统（老 ERP/新供应链/Excel 补录）、命名不统一（“鸡翅膀/翅中/鸡翅（中）”）、单位混乱（克/斤/箱）；
2. **承诺了超出数据支撑的技术指标**（“误差 15%以内”），而实际可达精度仅 65-75%；
3. **一次性承诺 6 个月全量交付**，无 Go/No-Go 节点；
4. **问题隐瞒 9 周**，客户信任崩塌于一次”8 公斤牛肉”的现场演示；
5. 演示**选择性展示**最优品类（樱桃数据），埋下信任炸弹。

复盘作者随后的重生项目证明了正确路径：**小切口（高价值食材当日用量监控）+ 已有数据 + 4 周上线 + 承诺业务结果 + 58 倍 ROI。**

本方案将上述 5 条教训全部转化为硬性设计约束，逐条落实如下：

1.2 反模式对策矩阵（本项目必须全部规避）

#	PDF 中的问题	本项目的硬性对策	落实位置
P1	签约前无数据质量	**Phase 0 即数据资**	§12.2

#	PDF 中的问题	本项目的硬性对策	落实位置
	评估	**产评估阶段**，交付《数据质量报告》并通过 Go/No-Go 评审后才进入开发	
P2	承诺技术指标（误差 15%)	**只承诺业务结果**：“试点门店高价值食材浪费率 3 个月内相对基线下降 ≥15%，未达标退还当期服务费”；技术指标仅作为内部验收参考并注明测量口径	§1.3
P3	6 个月一次性交付	四阶段交付（Phase 0-3），**每阶段独立合同额与 Go/No-Go 评审**，任一阶段可无责终止	§12
P4	隐瞒问题 9 周	**双周透明例会 + 周报制度 + 红黄绿灯看板**（Grafana 实时公开），风险/issues 全部进看板对甲方可见	§10.6
P5	演示挑好数据	演示与验收一律使用**全量真实数据 / 预注册的数据切片**，指标计算 SQL 随交付物公开，可复核	§10.6

#	PDF 中的问题	本项目的硬性对策	落实位置
P6	预订数据未接入致演示翻车	需求预测智能体**显式声明数据依赖清单**，缺依赖时系统自动降级并提示"预测置信度低"，禁止静默输出	§8.6
P7	三套格式数据无法对齐	建设**主数据管理（MDM）+ 数据质量门禁**：食材主数据统一编码（一品一码）、单位字典强制换算、BOM 标准化	§5.3

1.3 建设目标与业务承诺（承诺结果，不承诺指标）

愿景：为连锁餐饮企业构建一个可生长的"餐饮智能体平台"：以智能体（Agent）为核心交互范式，贯通"菜品—食材—采购—库存—浪费—预测—决策"全链路，并面向 C 端会员提供智能点餐/营销服务，平台具备支撑 **100 万注册用户** 的体系架构。

分阶段业务承诺（写入合同模板）： - Phase 1 后：试点门店高价值食材**当日用量差异（理论 vs 实际）T+1 可视**，差异>15%自动预警； - Phase 2 后：采购建议采纳率与浪费率基线对比**月度报告自动生成**，浪费率相对基线下降 ≥10%； - Phase 3 后：浪费率相对基线下降 ≥15%（3 个月滚动），否则退还当期服务费； - 全程：**所有指标的计算口径（SQL/脚本）随报告交付，甲方可独立复核。**

1.4 规格口径（防止"100 万人同时使用"的语义陷阱 —— 教训 P2 的直接应用）

"支撑 100 万人同时使用"必须定义清楚，否则就是 PDF 中"误差 15%"式的超支撑承诺。本方案采用国标/行业通行口径：

口径	数值	依据
注册用户	100 万	建设目标
日活（DAU）	10 万（10%）	连锁餐饮 C 端会员行业基准
峰值同时在线会话	1~2 万（DAU 的 10~20%）	互联网通行换算
峰值 API QPS（非 LLM）	5,000~10,000	峰值会话 × 平均请求速率 0.3~0.5 QPS/人
峰值 LLM 对话 QPS	50~200	受 CPU 推理物理上限约束（见 §11.2），通过语义缓存+分级路由+排队保障 SLO
数据存量	订单/流水 5 年 ≈ 1~2 TB（TiKV 600G 可支撑 2 年热数据，冷数据归档）	容量推演 §11.4

> **诚实声明**：两台服务器（合计 80 核 / 256GB / 无 GPU）物理上无法承载 100 万路**真实并发的 LLM 推理**。本方案通过”多级缓存拦截 80%+ 流量 + 意图分级路由 + 小模型优先 + 语义缓存 + 排队与降级”使 LLM 服务在上述口径下达标；若未来真出现百万级同时推理需求，需扩容 GPU 节点（架构已预留水平扩展点，见 §7.7）。**这是本方案与 PDF 失败项目的根本区别：把物理上限写在纸面上，而不是藏在演示后面。**

---

2. 现状勘察报告（集群资产实勘，2026-10-24）

2.1 计算资源

节点	IP	配置	角色	当前负载
k8s-master	10.167.2.175	16C / 128G / 500G	control-plane + worker	内存 ~93G 已用
k8s-worker1	10.167.2.176	64C / 128G / 500G	worker	内存 ~74G 已用

- K8S v1.28.2 / Docker 26.1.4 / Calico / **无 GPU（纯 CPU 推理）**

- 已装：Rancher 2.8.3、Istio、KubeVirt、ingress-nginx v1.11.1
- 镜像仓库：10.100.135.132:5000、10.167.2.175:30500、kube-system/docker-registry
- 存储类：local-path（默认）、nfs-client、pdm-local-ssd（TiKV 专用）

2.2 可复用中间件（infra / dify-plus 命名空间）——**本方案最大化复用，不重复建设**

类别	组件	版本	规模	用途
OLTP/OLAP	**TiDB**	v8.5.8	2×TiDB Server + 3×TiKV(各 200G) + 3×PD	主数据库，HTAP，**天然支持多 TiDB Server 读写分离**
缓存	Redis Cluster (redis8)	7.x/8.x	3 节点（30090-30092）	L2 缓存、分布式锁、会话
缓存	Redis 单机 (infra)	7-alpine	1 节点	备用/限流计数
消息	**Pulsar**	3.x	broker + 2 bookie + ZK	事件总线、削峰、领域事件
向量	**Milvus**	v2.6.6	standalone + etcd + minio	RAG 向量库、语义缓存
图谱	NebulaGraph	v3.8.3	metad+storaged +graphd	食材/菜品/供应商知识图谱
分布式 SQL	CockroachDB	-	3 节点	备选（不启用，避免多活脑裂）
网关	ingress-nginx	v1.11.1	1 副本	南北向流量入口（需扩容，见 §11.3）
注册配置	Nacos	2.5.0	缩容为 0	需时启用（Spring Cloud

类别	组件	版本	规模	用途
				配置中心)

2.3 AI 平台（ai-platform / dify 命名空间)

组件	版本/规格	说明
LiteLLM 网关	custom，NodePort 30083	统一 LLM 路由/配额/重试，OpenAI 兼容协议
Ollama	0.6.8	模型库：qwen2.5:72b/32b/14b、qwen3:32b/14b/8b/4b、deepseek-r1:7b、glm4:9b、llama3.1:8b、qwen3-embedding:8b/4b/0.6b、llama3.2-vision:11b、llava（多模态)
Dify	1.14.4（api×10 + worker×10)	低代码工作流/应用编排，用于运营侧快速搭建
vector-reranker	11.0.3	RAG 重排序服务（现成！)
kt-service	11.0.1	知识/图谱平台服务
open-webui / code-server / jupyterhub	-	教学配套

2.4 可观测性（monitoring 命名空间)

- kube-prometheus-stack：Prometheus + **Grafana 13.0.1（NodePort 30082）** + Alertmanager + node-exporter + kube-state-metrics
- **Loki 3.4.0** 日志聚合（刚部署 23h)
- 已有 dify/litellm/ollama 定制 exporter

2.5 勘察结论

1. **基础设施层完备度约 85%**，中间件全家桶齐备，本项目零采购、以复用为主；
2. 短板：① 无 GPU，LLM 吞吐受限 → 用”分级模型+缓存+队列”消化（§8.4)；② ingress-nginx 仅 1 副本 → 扩容为 2（每节点 1 副本)；③ 节点内存已用

58~72% → 需下线闲置负载（open-webui 0/0、attu 0/0 已缩容）并设置 Requests/Limits 限额治理；④ local-path 单点盘 → TiKV 已用 SSD 直通卷，其余有 NFS 可选。

---

3. 先进性分析与技术选型（2026-10 前沿调研结论）

3.1 智能体协议：MCP + A2A（Linux Foundation 双标准）

2026 年现状：**MCP（模型上下文协议）连接”智能体↔工具/数据”，A2A（Agent2Agent 协议）连接”智能体↔智能体”**，二者互补，均已成为 Linux Foundation 托管标准，A2A 首年即获 150+ 组织支持。业界亦有声音认为 A2A 落地负担偏重（Credal 2026-03）。

本项目选型：- 工具层**全面 MCP 化**：所有业务能力（查库存、下采购单、算差异）封装为 MCP Server，供任意智能体（自研/Dify/外部）标准化调用——这是 2026 年智能体互操作的事实标准；- 智能体间通信**预留 A2A 接口**（AgentCard 声明 + JSON-RPC over HTTP），但 Phase 1-2 以进程内编排为主，**不过度设计**（吸取 A2A 落地负担教训）。

3.2 编排框架：LangGraph 模式（有状态图编排）

LangGraph 已成为低层级有状态多智能体编排的主流框架，生产实践集中在 Supervisor/分层/专家并行三类模式。**选型**：智能体运行时采用 **Python 3.12 + LangGraph**（自研核心智能体），Dify 保留作运营侧低代码补充。复杂决策链采用 Supervisor 模式 + 专家子图并行（点单/库存/采购专家并行 → 汇总评审）。

3.3 可观测性：OpenTelemetry GenAI 语义约定

OTel GenAI 语义约定 2026 年已生产可用（LLM 调用/工具调用/MCP 均有标准 span 属性，Datadog 等已原生接入）。**选型**：全部服务接入 OTel → Prometheus/Loki（已有）；LLM 调用统一经 LiteLLM 网关埋点，质量评估（幻觉率/采纳率）以离线 Eval 平台（Ragas + 自建评审集）叠加。

3.4 API 层：GraphQL Federation

联邦网关 2026 三强：Apollo Router（Rust）、Hot Chocolate Fusion 16.5、Hive Router。**选型**：子图 = Spring for GraphQL（Java 21）；网关 = **Apollo Router Community（Rust）**，高吞吐、无 JVM 开销，适合本环境 CPU 预算。REST 保留给第三方回调/健康检查，内部东西向用 gRPC。

3.5 数据层：TiDB HTAP 读写分离

TiDB v8.5.8 兼容 MySQL 协议，多 TiDB Server 天然水平扩展，读写分离以"多 TiDB Server 实例 + 客户端读写分源"实现（详见 §7.4），无需额外中间件。

3.6 RAG 增强：混合检索 + 重排

Milvus 2.6（稠密）+ NebulaGraph（图检索：食材替代关系、菜品 BOM 图）+ BM25（TiDB 全文）三路召回 → 已有 vector-reranker 重排 → qwen3-embedding 系列做向量化。

3.7 先进性对标总结

维度	业界 2026 前沿	本方案落地
智能体互操作	MCP + A2A 双标准	工具层全 MCP；A2A 预留
编排	LangGraph 有状态图	LangGraph Supervisor + 专家并行
协议	GraphQL Federation	Apollo Router + Spring GraphQL 子图
数据	HTAP 读写分离	TiDB 多 Server 读写分离
检索	混合检索+重排	Milvus+图谱+BM25 → reranker
可观测	OTel GenAI 约定	全链路 OTel + Grafana/Loki
工程	DDD/TDD/BDD/SDD	见 §10

4. TOGAF 业务架构

4.1 业务能力地图

连锁餐饮智能体平台

```
├── B1 门店运营域      排班/出品/领料扫码/损耗登记
├── B2 菜品与 BOM 域    菜品/配方/食材主数据(一品一码)/单位字典
├── B3 采购域          供应商/询比价/采购单/收货对账
├── B4 库存与浪费域    出入库/盘点/理论用量 vs 实际/浪费预警 ← Phase1 核心
├── B5 需求预测域      分门店分 SKU 预测/置信度/数据依赖声明 ← Phase3
├── B6 会员营销域      C 端会员/券/积分/智能点餐助手(百万用户入口)
├── B7 智能体门户域    会话/编排/工具治理/评测
└── B8 数据平台域      MDM/数据质量门禁/指标/血缘 ← 反 P1/P7
```

4.2 核心业务流程（Phase 1 切口，源自 PDF 重生方案）

厨房领料扫码 → 当日实际用量自动归集

- → 与当日菜品销售×标准 BOM 计算"理论用量"
- → 差异 = 实际 - 理论；差异率 > 15% 的门店×品类
- → 智能体归因分析(以次充好?收货缺斤?工艺损耗?) → 企业微信/APP 预警采购主管

Phase 2 扩展到采购建议闭环，Phase 3 加入预测（数据成熟度达标后，且**预测结果永远带置信度与数据依赖清单**，缺数据时显式降级提示——反 P6）。

4.3 干系人与角色

角色	端	核心诉求
连锁总部运营/采购主管	管理 Web	T+1 浪费看板、预警、采购建议
门店店长/厨师长	移动 H5/PDA	领料扫码、损耗登记、当日差异
C 端会员	小程序/H5	智能点餐助手、会员权益
数据/IT 管理员	管理 Web	主数据治理、数据质量、智能体评测
教学场景（高职）	教学端	本平台同时作为 AI/大

角色	端	核心诉求
		数据实训载体

5. TOGAF 数据架构

5.1 数据分层

层	存储	内容
操作层	TiDB（infra）	各限界上下文的业务表（DDD 聚合落库）
缓存层	Redis Cluster	会话/热点菜单/库存快照/限流计数
检索层	Milvus + NebulaGraph + TiDB FT	向量/图谱/全文三路召回
事件层	Pulsar	领域事件（order.created / stock.consumed / waste.alerted）
历史层	TiDB 分区表 + NFS 归档	5 年流水，冷热分离

5.2 主数据模型（核心实体，一品一码）

```
erDiagram
    INGREDIENT ||--o{ BOM_ITEM : "进入配方"
    DISH ||--o{ BOM_ITEM : "由配方构成"
    BOM_ITEM }o--|| UNIT : "标准单位(克)"
    SUPPLIER ||--o{ SUPPLY_ITEM : "供货"
    INGREDIENT ||--o{ SUPPLY_ITEM : "被供应"
    STORE ||--o{ PURCHASE_ORDER : "采购"
    SUPPLIER ||--o{ PURCHASE_ORDER : "履约"
    DISH ||--o{ ORDER_ITEM : "售出"
    STORE ||--o{ STOCK_MOVEMENT : "领料/损耗"
    INGREDIENT ||--o{ STOCK_MOVEMENT : "对象"
    INGREDIENT {
        string ing_code PK "一品一码 IMG-xxxx"
        string name_std "标准名:鸡翅中"
```

```
    json aliases '["翅中","鸡翅膀","鸡翅（中）"]'
    string category
    string base_unit "克 g"
    decimal reference_price
}
```

别名机制直接消化 PDF 中”鸡翅膀/翅中/鸡翅（中）“三套命名的清洗问题：历史数据通过别名表自动映射，映射置信度不足的进入人工审核队列（而非静默丢弃）。

5.3 数据治理与质量门禁（反 P1/P7 的制度化）

1. **数据资产评估清单**（Phase 0 执行，直接采用 PDF 教训一的模板）：时间跨度≥2 年？关键字段缺失率<5%？单位可统一？影响变量（预订/天气/促销）可得性？
2. **质量门禁**：Great Expectations 风格的规则引擎部署于数据管道， freshness/完整性/一致性/异常值 四类规则，不达标数据进入隔离区并告警，**禁止带病进入指标计算**；
3. **单位字典**：全局唯一单位换算服务（1 斤=500 克，1 箱=按 SKU 定义），所有入湖数据强制过字典；
4. **指标口径版本化**：所有业务指标（浪费率、差异率）SQL 脚本入 Git，口径变更走评审——指标可被甲方独立复核（反 P5）。

---

6. TOGAF 应用架构（DDD）

6.1 限界上下文与服务划分

限界上下文	服务（Spring Boot 3 / Java 21）	职责	阶段
菜品与 BOM	`svc-recipe`	菜品/BOM/食材主数据/别名映射	P1
库存与浪费	`svc-inventory`	领料扫码/出入库/理论 vs 实际差异/预警	P1
智能体门户	`svc-agent-portal`	会话/SSE 流式/编排调度/工具治理	P1
Agent 运行时	`agent-runtime`（Python/	智能体图执行/记忆/反思	P1

限界上下文	服务（Spring Boot 3 / Java 21）	职责	阶段
	LangGraph）		
MCP 工具服务	`mcp-registry` + `mcp-fnb-tools`	MCP Server 注册与业务工具实现	P1
门店运营	`svc-store`	门店/员工/排班	P2
采购	`svc-procurement`	供应商/询比价/采购单/收货	P2
需求预测	`svc-forecast`（Python）	预测模型/置信度/依赖声明	P3
会员营销	`svc-member`	会员/券/积分（C 端百万入口）	P3
数据平台	`svc-mdm` + `job-quality`	主数据/质量门禁/指标计算	P1 起
前端	`web-admin`(Vue3) / `h5-store`(Vue3) / `mp-member`(小程序)	三端	P1-P3

6.2 分层与依赖（六边形/整洁架构，每服务内）

```
interfaces(REST/GraphQL/gRPC/MCP 适配) → application(用例编排)
  → domain(聚合/实体/领域服务/领域事件，纯净无框架依赖)
  → infrastructure(TiDB/Redis/Pulsar/Milvus 适配器)
```

跨上下文只允许：**领域事件（Pulsar）+ 开放主机服务（GraphQL 子图/gRPC/MCP）**，禁止跨库 join。

6.3 GraphQL 联邦设计

- 每个领域服务暴露 GraphQL 子图（Spring for GraphQL），实体按归属扩展（如 `Store.orders` 归 `svc-store`，`Order.items.dish` 归 `svc-recipe`）；
- Apollo Router 组合超级图，客户端**一次请求取全**，消除 REST 多跳（BFF 零拼装）；
- DataLoader 批量化 N+1；Persisted Query + 查询复杂度限制（防滥用）；

- 订阅（WebSocket/SSE）承载预警推送与智能体流式输出。

---

7. TOGAF 技术架构

7.1 部署拓扑（K8S，新增 namespace：`fnb-prod` / `fnb-staging`）

用户/门店/C 端 → ingress-nginx(扩至 2 副本) → Apollo Router(GraphQL 网关×2)
→ 各领域服务 Pod（多副本，HPA 按 CPU 自动扩缩）
智能体流量 → LiteLLM(已有) → Ollama(已有，qwen3:8b/14b 优先)
数据面 → TiDB(已有) / Redis Cluster(已有) / Pulsar(已有) / Milvus(已有)
可观测 → OTel Collector → Prometheus/Grafana/Loki(已有)

7.2 多级缓存（L0-L4，全局命中率目标 ≥80%）

级	位置	内容	TTL 策略
L0	CDN/nginx proxy_cache	静态资源、菜单海报	长，版本哈希
L1	进程内 Caffeine	菜品/BOM/单位字典（几乎不变）	30min+事件失效
L2	Redis Cluster	会话、门店库存快照、热点查询结果	秒级~分钟级
L3	**语义缓存（Milvus）**	LLM 问答对（问题向量→答案，相似度>0.92 直接命中）	按业务域
L4	数据库自身	TiDB 缓冲池	-

写路径：先写 TiDB → 发领域事件 → 失效 L1/L2（延迟双删+版本号），保证最终一致。

7.3 读写分离（TiDB 多 Server）

- 新增 1 个 TiDB Server 副本（共 3：`tidb-w`×1 专写、`tidb-r`×2 专读），K8S Service 拆分为 `tidb-write` / `tidb-read`；

- 应用侧双数据源（HikariCP），`@Transactional(readOnly=true)` 自动路由读源；MyBatis/Spring Data 天然支持；
- 报表/指标计算走只读源 + TiFlash 副本（v8.5 支持列存），避免影响交易；
- 缓存兜底：读 QPS 大头被 L1/L2 消化，DB 实际读压力预估 <1000 QPS。

7.4 消息与削峰（Pulsar）

- Topic 按领域事件划分（`fnb.inventory.consumed` 等），key=storeId 保证门店内有序；
- C 端秒杀/高峰下单 → Pulsar 队列削峰，消费端按 TiDB 写能力限速；
- 预警事件 → 独立 topic → 企业微信推送 + WebSocket 推送双通道。

7.5 网络与服务网格

东西向流量 Phase 1 用 K8S Service（简单可靠）；Istio 已装，Phase 2 可选启用金丝雀发布与 mTLS（不强依赖，避免复杂度前倾）。

7.6 GitOps 与 CI/CD

- 代码：Monorepo（`pnpm` + `Maven` + `uv` 多语言构建）或分仓（推荐 Monorepo，教学友好）；
- CI：构建→单测→契约测试→镜像→推 10.167.2.175:30500 仓库；
- CD：Kustomize/Helm 覆盖层 → `fnb-staging` 自动 → `fnb-prod` 手动审批（环境隔离）；
- 数据库变更：Flyway 版本化，禁止手工改库。

7.7 水平扩展预留

所有无状态服务可横扩；LLM 层预留“外部大模型 API 接入位”（LiteLLM 已支持多上游 failover）；若获 GPU，Ollama 换 GPU 镜像即插即用，架构零改动。

---

8. 智能体架构（核心先进性）

8.1 智能体清单

智能体	等级	模型	职责
用量差异分析 Agent	核心	qwen3:14b + 工具	归因差异（以次充好/缺斤/工艺），生成预警建议
采购建议 Agent	核心	qwen3:14b	结合预测+价格+库存生成建议单（人在环确认）
智能点餐助手（C 端）	高并发	qwen3:4b/8b 分级	会员问答/推荐/下单意图（**语义缓存命中率设计 70%+**）
需求预测 Agent	P3	统计模型+LLM 解说	LightGBM/Prophet 预测 + LLM 生成解释与置信度
数据质量巡检 Agent	辅助	qwen3:8b	数据质量报告生成、异常根因初判
运营知识问答 Agent	辅助	RAG	规章制度/操作 SOP 问答（Milvus+图谱混合检索）

8.2 编排模式（LangGraph，Supervisor + 专家并行）

```
Supervisor(意图分类/路由，qwen3:8b)
  ├→ 专家：库存差异分析 ─┐
  ├→ 专家：采购比价     ─┼─→ Reviewer(合规/幻觉校验，规则+小模型)
  ├→ 专家：知识检索 RAG ─┘          └→ 输出(带数据溯源与置信度)
  └→ 兜底：人工工单
```

- 记忆：会话级（Redis）+ 长期画像（TiDB + Milvus 向量记忆）；
- 反思：Reviewer 节点校验数字一致性（LLM 输出的用量差值必须来自工具调用结果，不得编造——**数字类回答强制工具溯源**）。

8.3 工具层（MCP）

mcp-fnb-tools 暴露：query_stock / compute_theoretical_usage / diff_analysis / create_alert / query_price / create_po_draft / search_knowledge 等；统一经 mcp-registry 注册鉴权，工具调用全程 OTel 埋点（MCP span 标准属性）。

8.4 LLM 流量治理（CPU 推理物理约束下的 SLO 保障）

请求 → L2 语义缓存(Milvus，相似>0.92 命中) →命中≈70%直接返回
→ 未命中 → 意图分级路由：
简单 FAQ/寒暄 → qwen3:4b （16 线程，吞吐高）
业务分析 → qwen3:14b（并发=2~4）
复杂归因 → qwen2.5:32b(并发=1，排队，P95≤30s)
→ 全链路排队(令牌桶)+熔断降级(返回引导语+工单)

实测口径将写入 Phase 0 POC 报告（CPU 推理吞吐实测 → 确定 SLO 承诺值，**先测后诺，反 P2**）。

8.5 评测（Eval）

- 评审集：每智能体 ≥200 条真实场景用例（含边界/对抗样本），入库版本化；
- 自动指标：工具调用准确率、数字一致性（幻觉率）、延迟、成本（token/次）；
- 流程：每次 Prompt/模型/链路变更必须跑回归评测，报告进 Grafana 看板（**对甲方透明，反 P4**）。

8.6 数据依赖声明机制（反 P6 的技术固化）

每个预测/分析类智能体在 agent-manifest.yaml 声明必需数据源；运行时前置检查数据新鲜度与完整性，不满足则：

```
输出 = { result: null, degraded: true, reason: "预订数据未接入(T+7)",
         fallback: "建议参考近 7 日均值", confidence: "LOW" }
```

禁止静默给出看似正常的低置信结果——“8 公斤牛肉”事件的技术级绝杀。

---

9. 安全与合规

项	措施	标准
等级保护	按等保 2.0 三级设计：双因子登录、审计日志、堡垒机操作留痕	GB/T 22239-2019
数据安全	手机号脱敏、PII 字段加密（K8S Secret+信封加密）、数据分级分类	GB/T 35273
软件文档	需求/设计/测试/部署文档全套	GB/T 8567-2006
软件质量	验收按质量模型执行	GB/T 25000.10
数据管理	数据资产目录+质量规则库	GB/T 36073 (DCMM)
API 安全	JWT+RBAC、GraphQL 深度/复杂度限制、限流（Redis 令牌桶）	OWASP API Top10
供应链安全	镜像扫描（trivy）、依赖 SBOM、私有仓库准入	-

10. 软件工程流程（DDD+TDD+BDD+SDD+CI/CD）

10.1 SDD（规格驱动，一切先有规格）

顺序：**业务事件风暴 → 领域模型（DDD）→ API 契约（GraphQL Schema / OpenAPI / MCP tool schema）→ 验收标准（Gherkin）→ 实现。**契约文件入库 `contracts/` 目录，前后端/智能体并行开发互不阻塞，契约测试（Pact/schemathesis）进 CI 门禁。

10.2 TDD

- 领域层单测覆盖率 ≥80%（Jacoco 门禁）；

- 测试金字塔：单元（JUnit5/Pytest）→ 组件（Testcontainers 连真实 TiDB/Redis/Pulsar）→ 契约 → E2E；
- 缺陷回归：每个 bug 先写失败用例再修复。

10.3 BDD

- 用户故事以 Gherkin 编写，例：

```
场景：高价值食材用量差异预警
  假如 2 号店 今日售出"黑椒牛柳"58 份 且 标准 BOM 牛肉用量为 150 克/份
  当 厨房领料扫码登记牛肉领用共 12.8 公斤
  那么 差异率为 -3.0% 不触发预警
  当 领料登记为 6.0 公斤 且 差异率 47.1%超过阈值 15%
  那么 系统 T+1 生成预警并推送采购主管 且 差异明细可溯源到每一笔单据
```

- Gauge/Cucumber 执行，测试报告附验收文档（可追溯矩阵：需求↔用例↔代码）。

10.4 DDD 战术规范

聚合划分（如 `PurchaseOrder` 聚合含明细，领料单 `StockMovement` 为独立聚合）、值对象（`Quantity{value, unit}` 强类型单位）、领域事件命名过去式、CQRS 仅在指标/报表读模型使用（不滥用于全系统）。

10.5 分支与版本

- 分支：trunk-based + 短生命周期 feature 分支；语义化版本；Conventional Commits；
- 每周发布列车，staging 全量回归 → prod 金丝雀（v1/v2 双 Deployment 切流）。

10.6 透明交付制度（反 P4/P5 的制度化，写入 SOW）

1. **双周演示例会**：永远现场随机抽门店/品类演示，禁止预选”樱桃数据”；
2. **周报自动化**：Grafana 交付看板（进度/缺陷/风险红黄绿灯）+ 数据质量看板公开链接；
3. **风险台账**：任何红/黄风险 24h 内书面知会甲方；
4. **指标口径全公开**：所有对外承诺指标的计算 SQL 随报告交付。

---

11. 容量规划与 SLO（含”100 万用户”达标推演）

11.1 资源预算（新增部署后的集群分配）

负载	副本	每副本资源	小计
Apollo Router	2	0.5C/512M	1C/1G
领域服务×9	各 2	0.5C/768M	9C/14G
agent-runtime	4	1C/2G	4C/8G
mcp-fnb-tools	2	0.5C/512M	1C/1G
前端/网关杂项	-	-	2C/4G
新增合计			**≈17C/28G**
集群当前空闲（估算）			≈40C/45G 可分配
Ollama 已占		qwen3:14b 常驻	已在存量内

结论：**资源可行，余量 50%+**；LLM 并发受 CPU 约束在 §8.4 框架内消化。

11.2 LLM 吞吐实测口径（Phase 0 POC 实测后锁定）

预估（16 核 CPU、qwen3:8b Q4）：单实例 8~15 tok/s、并发 2~4 路；qwen3:4b 可到 30+ tok/s。以”智能点餐助手平均回答 200 token、70% 语义缓存命中”测算： - 有效吞吐 ≈ (1-0.7)×请求走模型；4b/8b 混合约支撑 **60~150 QPS 真实推理**，匹配 §1.4 的 50~200 LLM QPS 口径。**Phase 0 以实测数据修订本表并锁定 SLO。**

11.3 瓶颈清单与对策

瓶颈	对策
ingress-nginx 单副本	DaemonSet/2 副本，每节点一个
节点内存占用已高	限额治理+闲置负载清理（列表见交付清单）
CPU 推理慢	分级模型+语义缓存+排队+降级话术
local-path 单点	有状态服务绑定固定节点+每日备份（velero/NFS）

瓶颈	对策
TiDB 写入热点	主键雪花化、分区表按月

11.4 存储推演

订单流水 100 万用户×10 万 DAU×2 单/日×365×2 年 ≈ 1.5 亿行（约 300G 含索引）→ TiKV 600G 前沿；>2 年冷数据归档 NFS（已有 nfs-provisioner）。

11.5 压测方案（load-testing namespace 已有）

- 工具：k6（HTTP/GraphQL/SSE）+ Locust（长尾场景）；
- 场景：①菜单浏览 10K QPS；②下单峰值 3K QPS；③智能助手 200 QPS（含 70% 语义缓存命中）；④预警推送 1 万 WebSocket 长连接；
- 通过标准（P95）：菜单 <100ms、下单 <300ms、智能助手首 token <3s、完整回答 <10s（简单类）；
- 报告随 Phase 2/3 验收交付，**压测脚本入库可复现。**

---

12. 分期实施计划（Go/No-Go 治理）

12.0 阶段总览（总工期 26 周，任一 No-Go 可无责终止）

Phase 0 数据评估+POC（3 周）—Go/NoGo→ Phase 1 MVP 单店切口（6 周）
—Go/NoGo→ Phase 2 采购闭环+32 门店模拟（8 周）—Go/NoGo→ Phase 3 预测+C 端+百万压测（9 周）

12.1 Phase 0：数据资产评估与 POC（3 周）——反 P1 的制度化

周	交付物
W1	数据资产盘点报告（源系统清单/字段映射/单位字典草案）
W2	《数据质量报告》（按教训一清单 9 项逐项打分）+ LLM 吞吐实测报告（锁定 SLO）
W3	POC：1 个门店 2 周真实数据跑通”领料→

周	交付物
	差异→预警”链路 + **Go/No-Go 评审会**

No-Go 标准示例：关键字段缺失率>20% 且无补充方案；或高价值食材无 BOM 可建立。此时止步，仅收评估阶段费用（对应 PDF 教训一”评估阶段收费”模式）。

12.2 Phase 1：MVP（6 周）——单一切口，跑通价值

范围：`svc-recipe`、`svc-inventory`、`svc-agent-portal`、`agent-runtime`（差异分析 Agent）、`mcp-fnb-tools`、`svc-mdm`+质量门禁、`web-admin`+`h5-store`（扫码）；3 家试点门店。 Go 标准：差异计算准确率（对账人工抽检 30 笔全对）、预警 T+1 送达率≥99%、试点店长可用性评分≥4/5。

12.3 Phase 2：采购闭环+模拟推广（8 周）

范围：`svc-procurement`、`svc-store`、采购建议 Agent（人在环）、32 门店模拟数据、全链路压测（第一轮）。 Go 标准：浪费率相对基线降≥10%（月度自动报告）、采购建议采纳率≥30%。

12.4 Phase 3：预测+C 端+百万压测（9 周）

范围：`svc-forecast`（带数据依赖声明与置信度）、`svc-member`+小程序点餐助手、语义缓存调优、百万用户全链路压测（§11.5 四场景达标）。 Go 标准：§1.3 业务承诺达成（浪费率降≥15% 或退费条款触发）、压测四场景全过、SLO 燃烧率<2×。

12.5 团队与工时（建议）

架构师 1（兼）、后端 2、前端 1、算法/Agent 1、测试 1、DevOps 0.5；甲方配合：业务专家 0.5、门店试点 3 家、数据接口人 0.5。

---

13. 风险管理（Top10）

风险	概率	影响	对策
历史数据质量差于预期	高	高	Phase 0 门禁+别名映射+人工审核队列

风险	概率	影响	对策
			预算
CPU 推理吞吐不达标	中	高	实测定 SLO+缓存+分级+预留外部 API 接入位
预测变量（天气/预订）接入受阻	中	中	预测功能依赖声明+降级输出+Phase 3 才上
节点内存紧张	中	中	限额治理+清理闲置负载+HPA
单点故障（2 节点集群）	中	中	备份恢复演练+服务反亲和+降级预案
智能体幻觉影响决策	中	高	数字强制工具溯源+Reviewer 校验+人在环
范围蔓延	高	中	Go/No-Go+变更评审委员会
门店扫码执行不到位	高	中	PDA/语音补录双通道+扫码率纳入试点考核
百万并发语义分歧	中	中	§1.4 口径写入合同附件
交付拖延	中	中	双周列车+红黄绿灯+缓冲 20%

14. 决策确认记录（V1.1 已锁定）

#	决策	结论（2026-10-24 甲方确认）
D1	“100 万”口径采用 §1.4	✅采纳
D2	技术栈 Java21+SpringBoot3（**Undertow+虚拟线程，排除 Tomcat**）/ Python **Litestar+Granian**（弃用 FastAPI）/ Vue3 前端	✅采纳（含修正）
D3	GraphQL 网关	MVP 用 Spring for GraphQL BFF，Apollo Router Phase 2 评估
D4	核心切口=高价值食材用量差异监控	✅执行
D5	Phase 0 评估先行（3 周）	✅同意
D6	起步数据=模拟数据（**≥1 亿条**入 TiDB + **Redis 集群 warmup**）	✅执行
D7	C 端载体	H5 先行，小程序资质另办
D8	教学实训包	Phase 3 后可选

附录 A · 引用来源（2026-10 调研）

- Linux Foundation: A2A 首年 150+组织
- Redis: MCP vs A2A / Google A2A 发布
- Credal: What happened to A2A?（2026-03）
- 2026 Agent 协议生态图
- LangChain: 多智能体架构选型（2026-01） / LangGraph
- OpenTelemetry GenAI 语义约定（2026-05） / spec 仓库

- Datadog 原生接入 OTel GenAI / Greptime: OTel 追踪 LLM/MCP（2026-05）
- Hive Router 高性能联邦网关 / Hot Chocolate Fusion 16.5（2026-07） / GraphQL Federation 2026 综述

附录 B · 标准规范清单

GB/T 8567-2006（软件文档）、GB/T 25000.10（质量模型）、GB/T 22239-2019（等保 2.0）、GB/T 35273（个人信息安全）、GB/T 36073（DCMM）、TOGAF 10、ISO/IEC/IEEE 42010、十二要素应用、CNCF 全景。