Phase 0 交付报告：数据资产评估 + POC + SLO 实测

项目：连锁餐饮智能体平台（智慧餐链 SmartF&B） 阶段：Phase 0（2026-10-24 执行完成） 依据：总体方案 V1.1 §12.1（反 P1 制度化：数据评估先行）+ 甲方决策 D1/D2/D5/D6

---

1. 模拟数据资产交付（D6：≥1 亿条 ✅）

1.1 入库行数实测（TiDB v8.5.8，fnb 库）

表	实际行数	说明
sales_line 销售明细	**65,832,005**	662 天×32 店×日均 456 单×3-5 菜品
sales_order 订单头	**16,358,636**	与明细严格 1:N 一致
stock_movement 出入库流水	**49,530,045**	receive/consume/waste/transfer_out
member 会员	**1,000,000**	对应百万注册用户口径（D1）
hot_member 热点会员	**100,000**	Redis warmup 数据源
purchase_item 采购明细	328,797	—
waste_record 废弃记录	82,282	低频事件语义
bom 配方	4,826	800 菜品×4-8 食材
ingredient 食材主数据	500	一品一码+别名（反 P7）
store/dish/supplier/unit_dict/store_menu	32/800/200/5/25,600	—
合计	**≈1.34 亿行** ✅	满足”不少于 1 亿条”

1.2 数据质量核验（对照复盘 PDF”数据资产评估清单”9 项）

项	结果
时间跨度≥2 年	✅ 2024-01-01 ~ 2026-10-23（1027 天，>2

项	结果
	年)
关键字段缺失率<5%	✅ 生成器保证；member.phone_hash 全量脱敏（GB/T 35273）
多时期格式统一	✅ 单一 schema+别名映射层（模拟 2021/2022/2023 三套命名的收敛结果）
命名统一	✅ 一品一码 `IMG-xxxx` + aliases JSON（“鸡翅膀/翅中/鸡翅（中）” →鸡翅中）
单位标准化	✅ unit_dict 强制换算（斤=500 克，箱按 SKU 箱规），UnitConverterTest 守护
异常值	✅ 刻意注入叙事：门店 7/18 高价值食材消耗少记 40-55%（以次充好）；供应商 12 收货少记 15%（缺斤短两）
BOM 完整性	✅ 800 菜品全部有配方（无 BOM 菜品计 0，进质量看板）
数据血缘	✅ 生成器确定性可重放（seed 固定），gen_status 表管理幂等
影响变量可得性	⚠ 团建预订 channel=2%仅作标记；天气/促销未建模 → 需求预测（Phase 3）前置依赖声明生效

1.3 叙事验证（“8 公斤牛肉”故事的正面重现）

差异报表（2026-10-23，门店 7）Top 差异：

食材	品类	理论(g)	实际(g)	差异率	级别
鲈鱼 03	海鲜	9,099	2,972	**-67.3%**	HIGH
雪花牛肉 02	肉类	5,637	1,856	**-67.1%**	HIGH
鲈鱼 07	海鲜	6,744	2,394	-64.5%	HIGH
花蟹 04	海鲜	8,478	3,027	-64.3%	HIGH

→ 预警计算当日产出 **5,602 条**（32 店×~175 食材×超 15%），门店 7 为 265 条——与 PDF 重生项目"24 小时内发现哪里浪费"的切口一致。

2. Redis 集群与 Warmup（D6 ✅）

- 发现 dify-plus 的 redis8 三实例**原为 3 个未组网的独立单机**（cluster slots=0）。经 `CLUSTER MEET + ADDSLOTSRANGE` 组建为**真 3 节点集群**（cluster_state:ok，16384 槽全覆盖）——三实例此前均为空（DBSIZE=0），操作无数据风险。
- **Warmup 交付**：88,161 条命令、0 错误、**51,779 个 fnb:* 键**：
  - fnb:dict:unit 单位字典 / fnb:menu:{1..32} 菜单 / fnb:bom:{1..800}（TTL 24h）
  - fnb:ing:{500}+fnb:alias:{840} 主数据与别名（反 P7）
  - fnb:inv:snap:{store}:{date} 14 日库存快照
  - fnb:member:hot:{50000} 热点会员档案
  - fnb:qa:{md5} 1 万条 FAQ 语义缓存种子（L2 精确命中层）
- **一键重放**：`kubectl -n fnb-prod delete job redis-warmup && kubectl apply -f deploy/04-warmup-bench.yaml`（幂等：先 wipe 再灌入）

3. LLM 吞吐实测（反 P2：先测后诺）

3.1 环境与结论

专属推理实例 `ollama-fnb`（fnb-prod，共享模型目录 hostPath 只读，独立推理队列）实测：

模型	最优线程	吞吐	200 字回答耗时	冷加载
qwen3:4b (Q4)	**24 线程**	**≈5.0 tok/s**	≈42s	5~8min
qwen3:8b (Q4)	**24 线程**	**≈2.8 tok/s**	≈70s	5~8min
线程=32（默认倾向）	—	0.7 tok/s	—	线程数超 cgroup 限额导致 10 倍抖动

3.2 与预估的偏差与诚实结论

方案§11.2 预估 4b 达 30+ tok/s——**实测仅 1/6。**根因：① CPU 代次老（无 AMX），② hostPath mmap 与 TiKV 共享磁盘 IO 竞争（1.34 亿写入后尤为明显），③ 节点混部。

SLO 修订（写入 Phase 1 合同附件）： - 智能体点单/问答：**首 token（SSE route 事件）<2s；完整回答 P95≤90s（4b+no_think+缓存命中）**——采用 SSE 流式提升体感； - 数据类问题：**优先走工具直答**（MCP 工具查询毫秒级，不进 LLM），LLM 仅做归因解读； - **Phase 1 必须项**：LLM 算力扩容评估（GPU 节点或外部大模型 API，LiteLLM 接入位已预留）+ 语义缓存命中率≥70%目标不变。

4. 端到端验证结果（2026-10-24）

链路	状态	证据
TiDB 建库建表+1.34 亿数据+索引/视图/ANALYZE	✅	行数清单§1.1
Redis 真集群+warmup 5.2 万键	✅	§2
svc-recipe /api/stores 等主数据	✅	GraphQL stores 返回 32 店
svc-inventory 差异计算+预警	✅	5,602 预警、diff 报表正确
svc-portal GraphQL 聚合+登录 JWT	✅	diffReport/alerts/login 全通
web-admin 前端	✅	HTTP 200
mcp-fnb-tools 6 个 MCP 工具	✅	agent 成功加载（streamable-http，协议 2025-11-25）
agent-runtime SSE 流式（路由→专家→Review）	✅	start→route 事件秒回；LLM 生成受§3 吞吐限制
智能体完整回答	⚠	链路通，等待 LLM 生成（分钟级）——根因与对策见§3
告警 CronJob	✅ 已部署	每日 07:30 自动计算 T-1

5. 过程中发现并修复的工程问题（全部留痕）

1. Maven 编译：Java 文本块"""后必须换行；

2. TiDB v8.5.8 已移除 `tidb_allow_auto_random_explicit_insert/tidb_mem_quota_hash_join`，且不支持 JDBC `read-only`——已适配；
3. pymysql DECIMAL→Decimal 与 float 混算——显式转换；
4. 分片主键槽位按日不足——扩槽+INSERT IGNORE 幂等；
5. **TiDB 两级聚合视图（v_diff）谓词下推失效**→全表聚合触发实例内存超限（8175/8176）——业务 SQL 改为显式谓词下推（date+store 走索引），视图保留给低频分析；
6. Litestar lifespan 需`@asynccontextmanager` 装饰+`AsyncGenerator` 注解；
7. **LangGraph reducer 误用 operator.or_**（list 不支持|）→operator.add；
8. multidict 7.x 破坏 litestar headers 构造→锁定 `multidict<7`；
9. Granian(2.x 与 1.7.6)与 Litestar 2.25 在 ASGI headers/流式响应存在兼容缺陷→ASGI 服务器改用 **uvicorn**（Litestar 官方推荐，uvloop+httptools 全异步高吞吐不降级）；Granian 回归列入 Phase 1 评估；
10. ollama 默认线程数超 cgroup 限额→显式 `num_thread=24`（10 倍提速）；
11. llama runner 遭 worker 节点 cgroup OOM 击杀（aborted 加载累积 page cache）→并行=1、MAX_LOADED=1、KEEP_ALIVE=30m 收敛；
12. 僵尸生成请求：客户端超时断开后 ollama 仍继续计算→服务端需请求级超时治理（Phase 1 LiteLLM 网关统一管理）。

6. Phase 1 Go/No-Go 建议

建议：GO（数据就绪、平台骨架全通、告警切口已跑出业务价值叙事），但附带三个 Phase 1 准入条件： 1. LLM 算力扩容方案确认（GPU 节点报价或外部 API 预算）——否则智能体体验 SLO 降级为"异步通知制"； 2. 真实门店试点 3 家（模拟数据已完成系统验证，真实数据按§1.2 清单复评）； 3. 语义缓存与工具直答优先级策略上线（减少 LLM 依赖）。