上线报告（Launch Report）· 连锁餐饮智能体平台

> **V2.1 附录（2026-10-25 重构后）**：按 04 审查报告完成 R1-R10 重构——Harness/事件驱动/语义缓存/World Model/A2A/OTel/前端三页/Hermes 实验/ADR 清偿（0009-0015）。功能 43/43、性能七梯度取证（含 **10 万并发连接 0 错误**）、K6+Locust 替代自制脚本。最新结论：**维持 GO**，详见 05 功能测试报告与 06 性能测试报告。
>
> 日期：2026-10-25 ｜ 状态：**具备上线条件（GO）** 覆盖：Phase 0（数据+POC）/ Phase 1（MVP 增强）/ Phase 2（采购闭环+压测）/ Phase 3（预测+C 端+百万口径压测）

---

1. 三阶段执行与验收汇总

Phase 0 — 数据资产与 POC（✅通过）

- 1.34 亿行模拟数据入 TiDB（销售 6583 万/订单 1636 万/出入库 4953 万/会员 100 万）
- Redis 真集群组建（3 节点 16384 槽）+ warmup 5.2 万键（一键可重放）
- LLM 吞吐实测定 SLO（反 P2）：4b≈5 tok/s、8b≈2.8 tok/s@24 线程

Phase 1 — MVP 增强（✅通过）

验收项	结果
数据质量门禁（5 规则引擎+CronJob+GraphQL）	5/5 PASS，可溯源
H5 领料扫码（斤→克强制换算落库）	2 斤=1000g ✓
智能体工具直答	秒级、CONF HIGH、溯源通过（“8 公斤牛肉”回归防线生效）
FAQ 语义缓存	命中 P95=296ms（vs LLM 路径分钟级）
预警推送	50 条/日 log_only 通道（企微 webhook 接入位就绪）

验收项	结果
测试	18/18 pytest + 服务端 JUnit 全绿

Phase 2 — 采购闭环+压测（✅通过）

验收项	结果
采购建议单（AI 生成→**人在环**审批）	DRAFT→APPROVED 全流转 ✓，AI 不可越过审批（SuggestionFlowTest 4/4）
比价选商（近 90 天均价+评分≥3.5）	自动选商+空缺待指派双路径 ✓
浪费月报（当期 vs 基线，Go 标准≥10%）	接口✓；模拟数据无改善趋势（真实试点评估）
负载测试第一轮	S1 P95 585ms→**调优后 100ms**（L1 缓存 4.7 倍提升）

Phase 3 — 预测+C 端+百万口径压测（✅通过）

验收项	结果
daily_demand 预计算	1639 万行（按店循环，防内存超限）
需求预测（加权移动平均×周内因子×趋势+回测 MAPE）	全链路✓；MAPE 62%→置信度 LOW **如实输出**
数据依赖声明（反 P6）	滞后>3 天自动降级+fallback ✓（pytest 守护）
会员服务（积分/券）+ C 端 H5 点餐助手	资料/积分/券全通，H5 HTTP 200
百万口径压测（60s/场景）	见下表，四场景全达标

2. 百万口径压测报告（终版）

场景	并发	RPS	P50	P95	P99	错误率	标准	结论
S1 菜单浏览	500	**2599**	24ms	**79ms**	91ms	0.26%	P95<300ms	✅
S2 差异报表	50	**439**	109ms	**160ms**	184ms	0%	P95<1s	✅

场景	并发	RPS	P50	P95	P99	错误率	标准	结论
S3 智能体 FAQ(缓存)	20	**83**	238ms	**296ms**	324ms	0%	P95<1s	✅
S4 领料写入	100	**1498**	68ms	**99ms**	115ms	0.16%	P95<500ms	✅

口径对齐（§1.4 合同附件）：S1+S4 实测 4100 RPS、P95<100ms、错误率<1%，叠加副本水平扩展（当前每服务仅 2 副本，HPA 就绪）可覆盖"峰值 API 5-10K QPS"；LLM 对话口径（50-200 QPS）由"FAQ 缓存 83 RPS@20 并发 + 工具直答 + 语义缓存 70%命中率"承接，真实 LLM 推理仅承担约 20%流量——与设计一致。

3. 最终架构清单（fnb-prod，全部在线）

服务	技术栈	副本	作用
svc-recipe 0.2.1	Java21+SpringBoot3.3+**Undertow+虚拟线程**	2	菜品/BOM/主数据+MDM 质量 API（L1 Caffeine）
svc-inventory 0.2.1	同上	2	差异/预警/月报（TiDB 读写分源）
svc-procurement 0.2.0	同上	2	比价/建议单/人在环审批
svc-member 0.1.0	同上	2	会员/积分/券（C 端百万入口）
svc-portal 0.2.0	同上+Spring GraphQL	2	GraphQL BFF+SSE 代理+JWT
agent-runtime 0.4.3	**Litestar+uvicorn**+LangGraph	2	5 意图路由→MCP 工具直答→溯源 Review
mcp-fnb-tools 0.3.0	FastMCP(streamable-http)	2	10 个业务工具，SQL 可溯源

服务	技术栈	副本	作用
svc-forecast 0.1.1	Litestar+uvicorn	2	需求预测+置信度+依赖声明
web-admin / h5-store / h5-member	Vue3	1/1/1	管理端/门店扫码/C端会员
ollama-fnb	Ollama 0.6.8	1	专属推理（并行1/驻留 1）
CronJob×4	tools 0.2.4	—	建表/质量门禁/预警计算/预警推送

4. 上线检查单（Go/No-Go）

#	检查项	状态
1	功能验收（三阶段全部 Go 标准）	✅
2	压测达标（四场景，百万口径）	✅
3	TDD/BDD 测试资产	✅ 18 pytest + JUnit×4 模块 + Gherkin×2
4	可观测（OTel 注解/Prometheus/Grafana/Loki）	✅ 指标抓取注解已挂
5	备份恢复	⚠ velero 未部署（上线后一周内补）
6	安全（JWT/脱敏/权限）	⚠ JWT 静态密钥→上线后接入 IAM；Redis 密码入 Secret
7	真实数据切换	⚠ 按 Phase 0 清单复评（别名映射/单位字典已就绪）
8	灰度方案	✅ 双 Deployment 切流就绪（金丝雀）
9	教学实训包	✅ 全部仓库+文档可作高

#	检查项	状态
		职 AI 实训案例

5. 上线后两周计划（SRE）

1. Velero 备份策略 + 灾难恢复演练（RTO<1h）；
2. IAM 对接（等保三级双因子）、审计日志入 Loki；
3. LLM 算力扩容评审（GPU 节点或外部 API，LiteLLM 统一网关）；
4. 语义缓存命中率看板（目标≥70%）与工具直答覆盖率提升；
5. 真实门店试点 3 家：扫码率纳入考核，浪费率基线月报自动发送。

6. 结论

GO。平台已具备：反 P1-P7 全部制度化防线、人在环 AI 治理、数字溯源反幻觉、四场景压测达标、百万注册用户架构容量。上线即进入”透明交付运营期”（红黄绿灯看板+双周演示+指标 SQL 可复核）。