多视角审查报告 与 重构升级方案 V2.0

审查日期：2026-10-25 ｜ 审查对象：连锁餐饮智能体平台（P0-P3 全部交付物） 审查方法：文档×代码×集群三方交叉核对（grep 级验证，非印象式审查）

状态：待甲方确认重构范围后执行（本报告含确认决策点§6）

---

1. 审查范围与方法

- 资料：docs/00-总体方案 V1.1、01-Phase0 报告、02-执行记录、03-上线报告
- 代码：smartfnb monorepo（9 服务+3 前端+工具链，Python+Java 约 3176 行）
- 集群：fnb-prod 20 Pod 实况、镜像版本、压测记录
- 关键审计手段：对方案中**声明的每项技术**做代码级 grep 验证（结果见§3 对照矩阵）

---

2. 五视角评分卡

2.1 招标师视角（合规与交付完整度）—— **8.0 / 10**

维度	得分	评语
文档规范（GB/T 8567）	8.5	方案/阶段报告/执行记录/上线报告齐全，版本可追溯
阶段门禁（Go/No-Go）	9.0	四阶段全部先测试后放行，证据链完整
透明交付（反 P4/P5）	9.5	12+项工程问题全留痕，压测数据未粉饰（LOW 置信度如实呈现）
声明闭环性	6.0	**方案声明的多项技术未落地或未闭环**（详见§3），招标答辩存在被质询风险
风险管理	8.0	Top10 风险表+3 项上线后补

维度	得分	评语
		强项诚实列示

一句话：过程治理是标杆级的，但”技术声明与交付实物的一致性”是最大失分点——评标专家对照技术方案逐条核验时会发现差距。

2.2 FDE 工程师视角（现场交付与客户价值）—— 8.5 / 10

维度	得分	评语
数据评估先行（反 P1）	9.5	质量门禁 5 规则制度化+可溯源，是复盘教训的最佳实践转化
承诺纪律（反 P2）	9.0	实测定 SLO、MAPE 62%如实标 LOW，拒绝编造
人在环治理	9.0	采购建议单 DRAFT→人工审批，AI 不可越权有测试守护
客户触点完整性	6.5	**采购审批/质量报告/需求预测有 API 但无 UI 页面**——对门店用户等于不可见
运维可交接性	7.5	run.sh 可重放，但无 CI 流水线、无备份演练（已列补强）

一句话：工程伦理执行到位，但”最后一公里”的界面缺失会让客户感知打折。

2.3 资深架构师视角（结构与性能）—— 7.0 / 10

维度	得分	评语
DDD/读写分离/HTAP	8.5	限界上下文清晰，TiDB 双数据源落地，谓词下推教训沉淀

维度	得分	评语
多级缓存	5.0	**L1 Caffeine✓；但 Redis 集群 warmup 的 5.2 万键无任何 Java 服务消费（grep 证实）**——属"建了仓没人取货"
事件驱动	3.0	**Pulsar 零使用**：领域事件未建，预警靠 CronJob 每日 07:30 轮询，"24h 发现"实际是"T+1 批处理"
GraphQL 演进	6.0	BFF 可用，但 D3 决策的"Apollo Router Phase 2 评估"未执行，决策悬空
可观测	5.5	Prometheus 指标✓；**OTel GenAI 语义约定零落地**，无 trace、无 LLM 调用链
容量与压测	7.0	4100+RPS/P95<100ms 达标，但用自制 aiohttp 脚本而非 K6/Locust（不可复核性差）
服务网格/网关	5.0	Istio/LiteLLM 勘察后未启用，无 ADR 记录"为什么不用"

一句话：骨架正确、性能达标，但三条"声明的支柱"（事件总线/语义缓存/可观测）是空心的。

2.4 AI 教授级高工视角（前沿技术落地诚实度）—— 6.0 / 10

维度	得分	评语
MCP 落地	8.5	✅真实落地：FastMCP+streamable-http

维度	得分	评语
		（协议 2025-11-25），10 工具 SQL 可溯源；缺注册中心/工具鉴权/MCP span
数字溯源反幻觉	9.0	numeric_guard+“8 公斤牛肉”回归测试，学术上站得住
A2A 协议	2.0	❌**未落地。**方案写”预留接口”，实际代码无 AgentCard、无 A2A endpoint——“预留”二字撑不起前沿性声明
世界模型（World Models）	0.5	❌**未采用。**无业务仿真层/数字孪生/what-if 推演——agent 决策前无法在”虚拟门店”上预演
Agent Harness	3.0	❌**未显式建设。**现有 LangGraph 图+guards 是雏形，缺标准 harness 的定义：统一工具循环、上下文工程、预算控制、评测回路（eval harness）
Hermes	0.5	❌**未评估。**无论是 Hermes 模型系（函数调用强）还是 Hermes 协议均未进入选型对比
评测体系（Eval）	4.0	有单测，无评审集回归、无幻觉率/采纳率指标看板
语义缓存（L3/Milvus）	2.0	❌方案§7.2 承诺”Milvus 相似度>0.92 命中 70%

维度	得分	评语
		+“，实际只有 Redis 精确 md5 匹配（FAQ），**向量语义缓存零实现**

一句话：MCP 与反幻觉是真功夫；但世界模型/Harness/Hermes/A2A/语义缓存五项在方案里”出现过名字”、在代码里”不存在实体”——这正是用户点名的要害，必须重构补齐或从方案中降级声明（二者只能选一，选前者）。

2.5 高级美工视角（体验与设计系统）—— **6.5 / 10**

维度	得分	评语
视觉一致性	7.5	Element Plus 规范使用，管理端/两 H5 风格统一
信息层级	7.0	差异看板主次分明，HIGH 红色警示有效
功能覆盖	5.0	**web-admin 仅 3 页（登录/看板/对话）**：采购审批、质量门禁、预测页缺失
移动端体验	6.5	H5 可用，但 PDA 扫码场景未做大按钮/防误触优化
无障碍(a11y)	4.0	未做对比度校验/键盘导航/ARIA 标注
设计系统	5.0	无 design tokens、无暗色模式、组件未抽离

2.6 加权总分

视角	权重	得分	加权
招标师	15%	8.0	1.20
FDE	20%	8.5	1.70
架构师	25%	7.0	1.75
AI 教授	30%	6.0	1.80

视角	权重	得分	加权
美工	10%	6.5	0.65
总分			**7.10 / 10**

3. 先进性声明 vs 实际落地 对照矩阵（本次审查核心产出）

#	方案声明	代码实证	判定	缺口性质
1	MCP”全面 MCP 化”（§3.1）	mcp-fnb-tools 10 工具，streamable-http	✅落地	补注册中心+鉴权+span
2	A2A”预留接口”（§3.1）	grep 无 a2a/ AgentCard	❌未落地	需最小可用实现
3	世界模型（未声明但属”最新技术”应评）	无仿真/孪生代码	❌未采用	新增 World Model 模块
4	Agent Harness（同上）	LangGraph 雏形非标准 harness	⚠雏形	重构为显式 harness
5	Hermes（同上）	零出现	❌未评估	加入选型对比实验
6	GraphQL Federation/Apollo Router（D3）	Spring GraphQL BFF	⚠降级未闭环	出 ADR 或升级
7	多级缓存 L2/L3（§7.2）	Java 零 Redis 引用；Milvus 零引用	❌空心	读路径接入 Redis+Milvus 语义缓存
8	Pulsar 事件总线（§7.4）	零使用	❌空心	领域事件重构
9	OTel GenAI 约	零引用	❌未接	otel-

#	方案声明	代码实证	判定	缺口性质
	定（§3.3）			collector+trace
10	NebulaGraph 图谱检索（§3.6）	零使用	⚠勘察未用	出 ADR（用/不用）
11	K6 压测（§11.5）	自制 aiohttp loadgen	⚠替代品	换 K6+Locust 正式套件
12	BDD Gherkin 执行（§10.3）	.feature 文件存在，无 Cucumber/behave 执行器	⚠有脚本无演出	接 behave 执行器
13	LiteLLM 统一网关（§8.4）	agent 直连 ollama	⚠绕行	经 LiteLLM 收口
14	Istio 金丝雀（§7.5）	未启用	⚠勘察未用	出 ADR

判定口径：✅=代码可验证落地；⚠=部分/替代/悬空；❌=声明与实物脱节。

---

4. 优化重构方案（R1-R10，按优先级）

P0（必做，直接回应审查要害）

R1 Agent Harness 显式化重构（回应”Harness 未落地”） - 新建 `agent-runtime/app/harness/`：`context.py`（上下文工程：会话记忆+检索注入+token 预算）、`loop.py`（标准工具循环：观察→行动→校验→反思，收敛当前 guards/direct/graph 散装逻辑）、`budget.py`（每会话 LLM token/调用数预算与熔断）、`eval.py`（评测回路：评审集≥100 条，每次 prompt/模型变更自动回归，输出幻觉率/工具准确率/成本到 Grafana） - 现有 5 意图路由全部收编进 harness，对外 API 不变

R2 事件驱动重构（Pulsar 落地） - 定义领域事件：`stock.movement.created`、`diff.alert.created`、`po.suggestion.approved` - svc-inventory 登记领料→发 Pulsar→消费者实时计算该店当日差异→超阈值**即时**推送（替代 07:30 轮询，“24h 内”升级为”分钟级”） - 月报/质量门禁改事件触发式补跑

R9(测试部分) K6+Locust 正式压测套件 - K6：S1 菜单/S2 报表/S4 写入/S5 会员/S6 预测六场景 JS 脚本，梯度 50/100/200/500/1000 并发×5min，输出 K6 summary（thresholds 硬编码进脚本，CI 可判） - Locust（Python）：S3 智能体 SSE 长连接场景（K6 对 SSE 流式支持弱）+ 混合业务流（浏览→点餐→领料→查差异 真实用户行为链） - 所有脚本+结果 JSON 入库 `tests/perf/`，报告模板见§5

P1（强烈建议，补齐声明）

R3 语义缓存真落地（Milvus+Redis 双层） - qwen3-embedding:0.6b（已有）向量化问题→Milvus 相似度检索（>0.92 命中直接返回，0.85-0.92 标注"参考"）→未命中走 harness→答案异步回写向量库 - 目标：LLM 调用量降 70%，命中率看板进 Grafana

R7 OTel GenAI 全链路可观测 - agent-runtime/mcp/forecast 注入 OTel SDK（gen_ai.*语义约定 span：model/prompt tokens/tool call） - 部署 otel-collector → 现有 Grafana（加 Tempo 做 trace 后端，或轻量用 Loki 存 span JSON）

R8 前端补全与设计系统 - web-admin 新增 3 页：采购审批（含一键 APPROVE/REJECT）、质量门禁看板（5 规则红绿灯+历史）、需求预测（7 日曲线+置信区间带） - 抽离 design tokens（色板/字号/间距 CSS 变量）、暗色模式、H5 扫码页大按钮防误触、a11y 对比度修复

P2（前沿探索，控制投入）

R4 World Model 业务仿真模块（回应"世界模型未采用"） - `world-model/`：基于 daily_demand 1639 万行拟合各店各食材需求分布（均值/方差/周内因子），提供 `simulate(store, ing, days, policy)` 蒙特卡洛接口 - 用途：采购建议生成前在 world model 上推演"买 50kg vs 40kg"的缺货/浪费期望成本，给出最优量；预测输出置信区间而非点估计 - 这是 CPU 环境可真实落地的"世界模型"形态（业务数字孪生），并在报告中明确学术口径：非神经世界模型（如 Genie 类），是基于统计仿真的业务世界模型

R5 A2A 最小可用实现 - agent-runtime 暴露 `/.well-known/agent-card.json`（能力/端点/鉴权声明） - 差异分析 agent 与采购 agent 以 A2A JSON-RPC 互调一次真实任务（跨 agent 委派采购建议），与 MCP 工具调用并存对照

R10 Hermes 评估实验 - 从镜像源尝试拉取 `hermes-3:8b`（或同级 function-calling 强化模型），与 qwen3:8b 在评测集上对比工具调用准确率/幻觉率；可行则作为 LLM_FAST 备选，不可行出 ADR 记录原因

R6 架构 ADR 清偿 - Apollo Router vs BFF、NebulaGraph、Istio、LiteLLM 四项各出一页 ADR（决策/理由/ revisit 条件），终结"勘察未用"悬空状态；LiteLLM 在 R3 后收口接入

工作量估算

包	内容	预估
P0	R1+R2+R9	3-4 天
P1	R3+R7+R8	3-4 天
P2	R4+R5+R10+R6	3 天
压测+报告	§5 全量级对比+两份报告	1-2 天

5. K6+Locust 测试计划（重构验收）

5.1 场景×梯度矩阵

场景	工具	并发梯度	时长/档	通过阈值
S1 菜单 GraphQL	K6	50/100/200/500/1000	5min	P95<300ms, err<1%
S2 差异报表	K6	10/30/50/100	5min	P95<1s
S4 领料写入	K6	30/100/300	5min	P95<500ms
S5 会员积分/券	K6	50/200/500	5min	P95<300ms
S6 需求预测	K6	10/30/60	5min	P95<2s
S3 智能体 SSE(缓存/直答/LLM 三档)	Locust	5/20/50	5min	直答 P95<1s
S7 混合业务流	Locust	20/50/100	10min	错误率<1%

场景	工具	并发梯度	时长/档	通过阈值
(真实用户链)				

5.2 量级对比分析框架（写入性能报告）

1. **重构前后对比**：同一梯度下 V1(当前) vs V2(重构后) 的 RPS/P95/P99/错误率（预期：S1 因 Redis L2 接入再提升、S3 语义缓存命中率>70%后 LLM 路径流量下降、S2 因事件预计算差异缓存化而降为毫秒级）
2. **量级间趋势**：每场景 RPS 随并发的扩展曲线（线性/拐点/饱和点定位——找到本集群单服务饱和并发，验证 HPA 扩容预案）
3. **资源关联**：压测期间 TiDB QPS/节点 CPU/Pod 内存（Prometheus 取数），给出"每千 RPS 资源成本"
4. **SLO 对照**：逐项对照§1.4 合同口径（峰值 API 5-10K QPS、LLM 50-200 QPS）判定达标余量

5.3 交付物

- `docs/05-功能测试报告.md`：六场景功能用例（含重构新增：harness 评测回路/事件驱动预警/A2A 委派/world model 仿真）×结果×缺陷清单
- `docs/06-性能测试报告.md`：K6+Locust 原始数据、五梯度对比表、扩展曲线图、资源成本、SLO 结论
- 结果回融：更新 00/03/README 中的性能数据与架构图（V2.1）

---

6. 待确认决策点

#	决策	建议
C1	重构范围：P0+P1+P2 全做 / 仅 P0+P1 / 仅 P0	✅建议全做（P2 是"前沿落地"的关键答辩点）
C2	World Model 形态：统计仿真数字孪生（CPU 可跑，本方案 R4）/ 坚持神经世界模型（需 GPU+训练周期，本环境不现实）	✅建议 R4 形态+学术口径说明

#	决策	建议
C3	A2A 落地深度：AgentCard+单任务委派（R5）/ 全服务 A2A 化	✅建议 R5 最小可用（避免 A2A 落地负担重演）
C4	Hermes：仅对比实验（R10）/ 不做	✅建议做实验，不可行则 ADR
C5	trace 后端：加 Tempo / span 入 Loki（轻量）	✅建议 Tempo（Grafana 原生）
C6	压测档位上限：1000 并发（单 master 压测源）/ 分布式 Locust 双节点	✅建议先 1000 单源，S1 不达再分布式

确认后执行顺序：R1→R2→R9 套件→（P1:R3→R7→R8）→（P2:R4→R5→R10→R6）→全量级压测→两份报告→资料回融。