ADR 集（Architecture Decision Records）· R6 清偿

状态：2026-10-25 ｜ 本文件清偿审查报告§3 矩阵中 4 项”勘察未用/悬空”决策，并记录 R1-R5 重构中的 2 项新决策。

ADR-0009 Apollo Router vs Spring GraphQL BFF（D3 清偿）

- **决策**：Phase 0-2 采用 svc-portal（Spring for GraphQL）作为组合 BFF，**不引入 Apollo Router**。
- **理由**：①子图数量 4 个，BFF 编译期组合已满足”一次请求取全”；② Router 为 Rust 二进制，本集群 CPU 代次<x86-64-v2 存在无法 exec 的风险（见 ADR-0012 实证）；③省一个独立网关组件的运维面。
- **revisit 条件**：子图>8 个 或 需要跨域联邦 join 时重评；届时优先评估 Hive Router（同 Rust 风险）与自研组合层。

ADR-0010 NebulaGraph 暂不启用

- **决策**：食材替代关系/BOM 图谱检索暂不接入 NebulaGraph；别名解析用 ingredient.aliases JSON + Redis 缓存满足。
- **理由**：当前查询模式（单跳别名/BOM）用关系型+JSON 即可，图谱多跳需求（如”替代品联动调拨”）属 Phase 4+场景。
- **revisit 条件**：出现 3 跳以上推荐/溯源查询时启用（集群已有 Nebula v3.8.3，接入成本低）。

ADR-0011 Istio 暂不启用

- **决策**：服务间东西向用 K8S Service + 客户端负载均衡；金丝雀用双 Deployment 切流。
- **理由**：20 Pod 规模下 sidecar 网格的运维/资源开销大于收益；压测显示 Service 路径 P95<10ms 非瓶颈。
- **revisit 条件**：服务数>15 或需要 mTLS 合规（等保三级测评项）时启用 Istio ambient 模式。

ADR-0012 OTel 采集器形态（新增，R7）

- **决策**：OTel SDK（GenAI 语义约定 span）→ **Console 导出器 → Pod stdout → Loki 聚合**；OTLP 端点可选叠加。
- **理由**：官方 collector 镜像（0.116.0 及 contrib）二进制要求 x86-64-v2，本集群 CPU（Xeon E5 代）不支持 exec——**三次实证**（otelcol、otelcol-contrib、mysql8 同因失败）。
- **影响**：span 以日志形式落 Loki（`gen_ai.*`关键字可检索），牺牲结构化查询效率换取零新增基建；GPU/新硬件到位后切换 OTLP→Tempo。
- **已落地证据**：agent-runtime 日志可见 `gen_ai.agent/tool/completion` span。

ADR-0013 语义缓存嵌入实现（新增，R3）

- **决策**：语义缓存嵌入默认用**字符 3-gram 稳定哈希（crc32，256 维，COSINE）**；qwen3-embedding 模型实现保留为可选（EMBED_IMPL=model）。
- **理由**：① qwen3-embedding:0.6b 在本集群实测冷加载 60-100s/请求 40s+（worker 负载 19/64+线程抖动），**无法满足在线命中检查≤2s 预算**；②哈希嵌入<1ms、确定性、跨进程一致（发现并修复了 Python 内建 hash()进程随机化缺陷）；③近义改写（怎么/如何/语序变化）验证可命中，阈值 HIT≥0.93/REF≥0.80。
- **影响**：哈希嵌入对深层语义改写（同义不同字）召回弱于模型嵌入——该类流量落入 LLM 路径并由 add_pair_async 自动学习回写，命中率随运行时间上升。
- **revisit 条件**：GPU 节点或低载窗口批量重嵌入时切回 model 实现（数据结构兼容，仅向量维度不同需双 collection）。

ADR-0014 Pulsar 生产网关形态（新增，R2）

- **决策**：Java 端发布走 **event-consumer 的 HTTP 网关(:8081/publish)** → Pulsar python 客户端生产；不引入 Java Pulsar 客户端。
- **理由**：TiDB/Pulsar shared 集群的 admin REST 在该版本未开放 HTTP 生产(404)；Java 客户端引入 SDK 版本矩阵成本>一个 48 行网关服务。
- **revisit 条件**：Pulsar 升级至开放 REST 生产的版本，或 Java 侧需要 exactly-once 语义时引入原生客户端。

ADR-0015 主推理模型维持 qwen3:8b（Hermes 实验结论，R10）

- **决策**：线上 LLM_MAIN 维持 qwen3:8b；hermes3:8b 作为 GPU 环境首选备选（模型已入 hostPath 库）。
- **实验数据**（tools/llm-bench/hermes_vs_qwen.py，n=6）： | 模型 | 结构化工具遵循 | 平均延迟 | |—|—|—| | hermes3:8b | **4/6 (66.7%)** | **11.6s** | | qwen3:8b | 1/6 (16.7%) | 70.9s | hermes 单请求工具调用 53s 冷启动后稳定，且 get_diff 参数 100%正确。
- **不立即切换原因**：fnb-ollama 驻留 3 模型（8b+4b+embedding）下 hermes 加载引发反复驱逐（实测单次 60-120s）——2 节点 CPU 混部环境不可承载 4 模型驻留。
- **revisit 条件**：GPU 节点到位或 LLM 流量显著上升时，hermes3:8b 为主、qwen3:4b 为快路径。

ADR-0016 portal→agent WebClient 显式 JDK HttpClient HTTP/1.1（V3 回归新增，2026-10-26）

- **状态**：已采纳（svc-portal 0.1.3）
- **背景**：无头浏览器回归发现 /api/agent/chat 全链路 500。排查：pom 排除 reactor-netty 后，Spring WebClient 回落到 JDK HttpClient，其对 `text/event-stream` 目标自动附加 `Connection: Upgrade` + `Upgrade: h2c`（HTTP/2 prior-knowledge 协商）；Litestar/uvicorn 将带 Upgrade 头的 POST 按升级语义处理，返回 400 `Validation failed: 'data'`。
- **决策**：`Clients.agentWebClient` 显式构造 `JdkClientHttpConnector(HttpClient.Version.HTTP_1_1)`，禁用协议升级协商。
- **后果**：SSE 桥接恢复（端到端 0 失败）；代价是放弃 h2c 多路复用（内网单跳场景无实际收益）。
- **关联**：D-06；配套前端 D-05（graphql 改 POST）、D-07（SSE `data:` 帧兼容 + Vue 响应式整体替换）于 web-admin 0.1.5 修复。