10-停机腾退与恢复手册（V3·2026-10-26）

> 目的：项目演示/测试结束后暂停全部应用服务，腾退两节点 K8S 集群资源；保留 Deployment/ConfigMap/Service 定义与本地镜像仓库，**可随时一键恢复。** 公共依赖（不动）：TiDB（infra）、Redis 集群（dify-plus）、Pulsar、Milvus、共享 Ollama（ai-platform）、注册中心 10.167.2.175:30500。

一、本次停机快照（2026-10-26）

对象	处置	状态
14 个 Deployment（fnb-prod）	副本归零 `--replicas=0`	✅ 0 Pod
3 个 CronJob（alert-compute/alert-push/quality-check）	`spec.suspend=true`	✅ 不再触发
遗留测试 Pod（k6/locust/zombie）	已清理（含 1 个 ContainerStatusUnknown 强删）	✅
已完成历史 Job	保留（不占资源，可审计）	—
镜像	全部 15 个已在本地仓库 10.167.2.175:30500	✅ 见下表

本地镜像清单（恢复依据）

组件	镜像
agent-runtime	fnb/agent-runtime:0.6.5
event-consumer	fnb/event-consumer:0.2.2
h5-member / h5-store	fnb/h5-member:0.1.0 / fnb/h5-store:0.1.0
mcp-fnb-tools	fnb/mcp-fnb-tools:0.4.0
ollama-fnb	**fnb/ollama:0.6.8（本轮由 10.100.135.132:5000 重注册至本地仓库，deployment 镜像引用已切换）**

组件	镜像
svc-forecast/inventory/member/portal/procurement/recipe/worldmodel	fnb/svc-*:0.1.1/0.3.3/0.1.0/0.1.3/0.2.0/0.2.1/0.1.0
web-admin	fnb/web-admin:0.1.5
工具链	fnb/tools:0.3.2（warmup/quality）、perf/k6:0.1.3、perf/locust

资源腾退效果

- master：CPU 30%→17%，内存 52%→50%
- worker1：内存 73%→69%，CPU 52%→51%（另有共存业务，fnb 贡献部分已释放）
- fnb-prod 运行 Pod：25+ → ◐

二、恢复操作（按需）

2.1 一键恢复全部（标准 2 副本）

```
for d in agent-runtime event-consumer h5-member h5-store mcp-fnb-tools \
         ollama-fnb svc-forecast svc-inventory svc-member svc-portal \
         svc-procurement svc-recipe svc-worldmodel web-admin; do
  kubectl -n fnb-prod scale deploy/$d --replicas=2
done

# web-admin 单副本
kubectl -n fnb-prod scale deploy/web-admin --replicas=1
```

2.2 恢复定时任务

```
kubectl -n fnb-prod patch cronjobs alert-compute alert-push quality-check -p
'{"spec":{"suspend":false}}'
```

2.3 数据层 cold-start 顺序（若公共依赖也重启过）

1. TiDB / Redis 集群确认 healthy；
2. Redis warmup：`kubectl -n fnb-prod delete job redis-warmup --ignore-not-found` `kubectl -n fnb-prod apply -f deploy/04-warmup-bench.yaml`（镜像 fnb/tools:0.3.2）；
3. db-init 仅首次部署需要（数据仍在 TiDB，勿重复执行避免清库）。

2.4 恢复后验证

```
kubectl -n fnb-prod get pods           # 全部 Running
curl -s http://10.167.2.175:30250/ -o /dev/null -w "%{http_code}\n"   # 200
curl -s -N -X POST http://10.167.2.175:30250/api/agent/chat -H 'Content-Type: application/json' \
  -d '{"question":"7 号店 2026-10-23 牛肉用量差异","storeId":7,"date":"2026-10-23"}' --max-time 60  # SSE answer 事件
```

三、注意事项（历史教训沿用）

1. **永远不用 `kubectl set env` 改 Deployment**（会触发重建回滚镜像）；改配置一律 `apply -f` 或 `set image`；
2. `set image` 后须用 `imageID` 核对双节点 digest 一致（本轮曾出现 worker 缓存旧 digest 导致修复未生效）；
3. TiDB 数据（1.51 亿行）在 infra 命名空间，未受本次停机影响；
4. 恢复后首次对话较慢属正常（Ollama 模型冷加载 40-120s）。